

4.18 피드백

머신러닝 기초 피드백: 군집화(Clustering)의 이해와 활용

이번 주차에서는 정답(Label)이 없는 상태에서 데이터의 내재적 패턴을 찾아 그룹을 형성하는 군집화(Clustering)에 대해 다루었습니다.

실무에서는 정답이 부여되지 않은 대규모 데이터(예: 로그 데이터, 고객 정보 등)를 다루는 경우가 많습니다. 이러한 데이터를 유사성에 기반하여 묶어내는 군집화는 고객 세분화 및 추천 시스템의 기초가 됩니다. 주요 군집화 알고리즘의 특징과 활용 방안을 정리해 드립니다.

1. K-평균 (K-Means) 알고리즘

K-Means는 데이터를 가장 가까운 중심점(Centroid)에 할당하고 중심점을 지속적으로 업데이트하는 과정을 반복하여 군집을 형성합니다.

- **특징:** 거리 기반 알고리즘으로 구조가 직관적이고 연산 속도가 빠릅니다.
- **활용 예시:** 방대한 고객 데이터를 K개의 그룹으로 나누어 고객 세분화(Segmentation)를 진행할 때 베이스라인 모델로 자주 활용됩니다.
- **확장 개념 (Vector Quantization):** 연속적인 고차원 데이터를 K개의 이산적인 값으로 압축하는 벡터 양자화의 기본 원리로 쓰이며, 이는 추후 딥러닝의 VQ-VAE(Vector Quantized Variational Autoencoder) 같은 모델의 수학적 근간이 됩니다.

2. 군집 평가 (실루엣 계수)

비지도 학습인 군집화는 정답(Label)이 없으므로 모델의 성능을 평가하기 위해 실루엣 계수(Silhouette Coefficient)와 같은 지표를 사용합니다.

- **원리:** 동일 군집 내의 데이터들이 얼마나 밀집해 있는지(응집도), 그리고 다른 군집의 데이터들과는 얼마나 멀리 떨어져 있는지(분리도)를 -1에서 1 사이의 값으로 나타냅니다. 1에 가까울수록 군집화가 잘 이루어진 것을 의미합니다.
- **활용 예시:** 최적의 군집 개수(K)를 사전에 알 수 없을 때, K 값을 변경해가며 실루엣 계수를 비교하여 가장 적절한 군집 수를 논리적으로 결정하는 데 활용합니다.

3. GMM (Gaussian Mixture Model)

데이터가 특정 군집에 속한다고 단정 짓는 K-Means(Hard Clustering)와 달리, GMM은 데이터가 여러 개의 가우시안 분포(정규 분포)의 혼합으로 생성되었다고 가정하는 확률 기반 군집화 모델입니다.

- **원리:** 특정 데이터가 각 군집에 속할 '확률'을 계산하여 유연하게 군집을 할당합니다 (Soft Clustering). 분산과 공분산을 고려하므로 타원형으로 분포된 데이터 군집도 효과적으로 식별할 수 있습니다.
- **확장 개념:** 데이터의 확률 분포를 추정한다는 점에서, 데이터 생성 모델의 시초격으로 볼 수 있습니다. 이는 향후 딥러닝에서 VAE나 확산 모델(Diffusion Model)과 같은 생성형 모델의 통계적 배경지식으로 연결됩니다.



Quiz: 상황에 따른 군집화 알고리즘 선택

다음 두 가지 상황에서 K-Means와 GMM 중 어떤 모델을 사용하는 것이 더 적합한지 생각해 보세요.

- **상황 A:** 대규모의 문서 텍스트 데이터를 빠르게 100개의 임시 카테고리로 분류해야 하며, 연산 속도와 효율성이 가장 중요한 상황입니다.
- **상황 B:** 고객의 행동 패턴 데이터를 분석할 때, 데이터가 원형이 아닌 타원형으로 분포되어 있고, 한 고객이 여러 카테고리에 속할 확률(예: A성향일 확률 60%, B성향일 확률 40%)을 동시에 도출해야 하는 상황입니다.

[정답 및 해설]

- **상황 A (K-Means):** 데이터 규모가 크고 빠른 연산이 필요할 때는 직관적이고 수렴 속도가 빠른 거리 기반의 K-Means 알고리즘이 압도적으로 유리합니다.
- **상황 B (GMM):** 데이터가 비원형(타원형) 분포를 가지며, 확률 기반의 유연한 분류 (Soft Clustering)가 필요하므로 분산과 공분산을 모두 반영하는 GMM이 적합합니다.