

새싹반NLP, 머신러닝 수학

오늘 볼 큰 그림

1

텍스트를 숫자로 바꾸기

2

문서-단어 행렬 만들기

3

분류와 유사도 계산하기

4

핵심 수학만 연결하기

이번 자료는 현대 생성 모델이 아니라, **머신러닝 기반 텍스트 분석**을 이해하는 데 필요한 흐름만 다룹니다.

텍스트 분석 이해: NLP란?

핵심 개념

NLP는 사람이 쓰는 문장을 컴퓨터가 계산 가능한 형태로 바꾸고, 분류/검색/생성 같은 작업을 수행하는 분야입니다.

왜 중요한가

리뷰 감성 분석, 스팸 탐지, 뉴스 분류, 문서 검색, 유사 문서 추천이 모두 텍스트 분석의 대표 문제입니다.

학습 포인트

텍스트 자체를 바로 모델에 넣을 수 없기 때문에, **토큰 -> 벡터 -> 모델 -> 평가** 흐름을 먼저 잡습니다.

간단한 예시

"배송이 빠르고 좋아요"라는 문장을 긍정 리뷰로 분류하려면 먼저 단어 조각들을 숫자로 바꿔야 합니다.

머신러닝 NLP 파이프라인

Text

문장과 라벨 수집

Clean

정제와 토큰화

Vectorize

BoW / TF-IDF

Train

분류기 학습과 평가

핵심은 문장을 숫자 벡터로 바꾼 뒤, 기존 머신러닝 모델이 처리할 수 있는 표 형태 데이터로 만드는 것입니다.

대표 텍스트 표현 방법

방식	대표 표현	장점	한계
BoW / TF-IDF	단어 출현 횟수, 중요도	간단하고 빠름	문맥과 단어 순서를 많이 잃음
Word Embedding	단어를 dense vector로 표현	비슷한 단어가 가까워짐	기본 머신러닝 수업에서는 BoW/TF-IDF 뒤에 학습

텍스트 정제와 토큰화

원문: "배송이 너무 빠르고, 품질도 좋아요!!!"

정제: "배송 빠르 품질 좋"

토큰: ["배송", "빠르", "품질", "좋"]

- 정제는 불필요한 기호, 중복 표현, 분석에 방해되는 요소를 줄이는 과정입니다.
- 토큰화는 문장을 모델이 셀 수 있는 단위로 나누는 과정입니다.
- 한국어는 조사와 어미가 붙기 때문에 형태소 분석이 도움이 될 수 있습니다.

BoW: 단어를 세는 방식

핵심 개념

Bag of Words는 문서에 어떤 단어가 몇 번 나왔는지 세어 문서를 벡터로 표현합니다.

왜 중요한가

가장 단순하지만 텍스트 분류의 기본 흐름을 이해하기 좋습니다.

학습 포인트

단어 순서는 거의 잃지만, 단어 출현 패턴을 표 형태로 만들 수 있습니다.

간단한 예시

"영화 재미있다"와 "영화 재미있다 재미있다"는 "재미있다" 횟수가 다르게 기록됩니다.

BoW 예시: 문서-단어 행렬

문서	영화	재미	별로	추천
"영화 재미 추천"	1	1	0	1
"영화 별로"	1	0	1	0

이 행렬의 행은 문서, 열은 단어입니다. 이 형태가 되면 로지스틱 회귀, 나이브 베이즈, SVM 같은 모델에 넣을 수 있습니다.

TF-IDF: 흔한 단어는 낮게

핵심 직관

문서 안에서 자주 나오지만, 모든 문서에 흔하지 않은 단어를 더 중요하게 봅니다.
"영화"처럼 어디에나 나오는 단어보다 "감동", "환불", "고장" 같은 단어가 더 구분력이 있을 수 있습니다.

모델 연결

TF-IDF 벡터는 텍스트 분류와 문서 유사도 계산에서 자주 쓰이는 기본 입력입니다.
CountVectorizer보다 단어 중요도를 더 세밀하게 반영할 수 있습니다.

문서 유사도: Cosine Similarity

A: "배송 빠르 품질 좋"

B: "배송 빠르 포장 좋"

C: "환불 불만 고장"

- A와 B는 겹치는 단어가 많아 벡터 방향이 비슷합니다.
- A와 C는 사용하는 단어가 달라 벡터 방향이 멀어질 가능성이 큼니다.
- 코사인 유사도는 문서 벡터의 **크기보다 방향**이 얼마나 비슷한지 봅니다.

텍스트 분류 예시

핵심 개념

텍스트 분류는 문장을 벡터로 바꾼 뒤 정해진 라벨 중 하나를 예측하는 문제입니다.

왜 중요한가

감성 분석, 스팸 탐지, 뉴스 카테고리 분류가 모두 같은 흐름으로 풀립니다.

학습 포인트

입력은 TF-IDF 행렬, 출력은 라벨입니다. 모델은 어떤 단어가 어떤 라벨과 가까운지 학습합니다.

간단한 예시

"재구매하고 싶어요"는 긍정, "다시는 안 살래요"는 부정으로 분류합니다.

평가 지표도 함께 봐야 함

지표	의미	NLP 예시
Accuracy	전체 중 맞힌 비율	일반적인 뉴스 분류
Precision	양성이라고 한 것 중 진짜 양성 비율	스팸이라고 차단한 메일의 신뢰도
Recall	실제 양성 중 찾아낸 비율	악성 댓글을 놓치지 않는 능력
F1-score	Precision과 Recall의 균형	클래스 불균형이 있을 때 유용

왜 수학이 필요한가?

Matrix Decomposition

문서-단어 행렬처럼 큰 행렬에서 중요한 축과 숨은 구조를 찾게 해줍니다.

Vector Calculus

분류 모델이 틀렸을 때 가중치를 어떤 방향으로 고칠지 이해하게 해줍니다.

이번 자료에서는 전체 수학 목록 중 **Eigen, SVD, Gradient**만 우선순위로 봅니다.

MML CH4: 정말 중요한 것만

우선순 위	개념	NLP 연결
높음	Eigenvalues / Eigenvectors	PCA, 중요한 데이터 방향, 분산 이 큰 축
높음	Singular Value Decomposition	문서-단어 행렬의 숨은 주제, 차 원 축소
높음	Matrix Approximation	큰 행렬에서 중요한 정보만 남 기기

Eigenvectors: 중요한 방향

$$A v = \lambda v$$

핵심 개념

행렬을 곱해도 방향은 그대로이고 길이만 바뀌는 특별한 방향이 eigenvector입니다.

왜 중요한가

데이터가 가장 많이 퍼져 있는 방향, 즉 PCA의 핵심 아이디어와 연결됩니다.

학습 포인트

eigenvalue는 그 방향이 얼마나 강한지 알려주는 배율입니다.

간단한 예시

리뷰 데이터에서 긍정/부정 표현을 잘 가르는 방향이 있다면, 그 방향이 중요한 축입니다.

SVD와 Matrix Approximation

$$A = U \Sigma V^T$$

SVD

어떤 행렬이든 중요한 방향과 그 크기로 나누어 볼 수 있는 분해입니다.
문서-단어 행렬에서 숨은 주제 구조를 찾는 데 연결됩니다.

Approximation

중요한 성분 몇 개만 남겨도 원래 행렬을 어느 정도 설명할 수 있습니다.
차원 축소, 노이즈 제거, 추천 시스템의 잠재 요인과 연결됩니다.

MML CH5: 정말 중요한 것만

우선순 위	개념	NLP 연결
높음	Partial Differentiation and Gradients	모델 가중치를 어느 방향으로 바꿀지 계산
높음	Gradients of Matrices	TF-IDF 행렬과 가중치 행렬의 shape 이해
중간	Useful Identities	공식보다 shape과 계산 흐름 중심으로 확인

Gradient: 가중치를 고치는 방향

```
w_new = w_old - learning_rate * gradient
```

감성 분석 모델이 "별로다"가 들어간 리뷰를 긍정으로 잘못 예측했다면, 손실이 커지고 관련 가중치를 부정 방향으로 조정합니다.

- Gradient는 손실이 가장 빠르게 증가하는 방향입니다.
- 학습은 그 반대 방향으로 이동해 손실을 줄입니다.
- 텍스트 분류에서도 모델은 단어 특성과 라벨 사이의 가중치를 이런 방식으로 조정합니다.

자율 학습 체크리스트

[] 텍스트를 숫자 벡터로 바꿔야 하는 이유를 설명할 수 있다.

[] 정제, 토큰화, 벡터화의 차이를 설명할 수 있다.

[] BoW와 TF-IDF의 차이를 설명할 수 있다.

[] 문서-단어 행렬이 무엇인지 설명할 수 있다.

[] 코사인 유사도가 문서 유사도에 쓰이는 이유를 설명할 수 있다.

[] 텍스트 분류의 전체 학습 흐름을 설명할 수 있다.

[] eigenvector와 SVD가 중요한 축/차원 축소와 연결됨을 설명할 수 있다.

[] gradient가 가중치 수정 방향이라는 점을 설명할 수 있다.

마무리

머신러닝 NLP의 핵심은 "문장을 정제하고, 단어 기반 벡터로 바꾸고, 분류/유사도 문제로 푼다"는 흐름입니다.

- Matrix Decomposition은 문서-단어 행렬에서 중요한 축과 숨은 구조를 보게 해줍니다.
- Vector Calculus는 분류 모델이 손실을 줄이며 가중치를 고치는 방식을 이해하게 해줍니다.
- 지금은 BoW, TF-IDF, 유사도, 분류 평가를 먼저 정확히 잡는 것이 중요합니다.

다음 주차 예고: Backpropagation

다음 주차에서는 모델이 손실을 줄이기 위해 가중치를 어떻게 거꾸로 따라가며 수정하는지, Backpropagation을 조금 더 공부해보겠습니다.

- 오늘은 gradient가 "가중치를 고치는 방향"이라는 직관까지만 잡습니다.
- 다음에는 여러 층의 모델에서 gradient가 어떻게 전달되는지 살펴봅니다.
- 머신러닝에서 딥러닝으로 넘어갈 때 꼭 필요한 연결 개념입니다.