

#1. 미션 소개

고객 이탈 예측은 이커머스 기업의 CRM 팀과 그로스팀에서 수행하는 핵심 업무다. 신규 고객 획득 비용은 기존 고객 유지 비용의 5 배 이상이며, 이탈률을 5%만 낮춰도 수익이 25% 이상 증가할 수 있다. 쿠팡, 마켓컬리, 무신사 등 국내 주요 이커머스 기업에서는 단순히 이탈을 예측하는 것을 넘어, 마케팅 개입이 효과 있는 고객을 식별하고 제한된 예산 내에서 최적의 리텐션 전략을 수립한다. 이 미션에서는 고객 행동 시뮬레이터를 직접 구현하여 다양한 고객 페르소나의 구매, 방문, 이탈 패턴을 생성한다. 코호트 분석으로 가입 시점별 이탈 패턴을 파악하고, RFM 분석과 행동 변화 피처를 설계한다. ML/DL 모델로 이탈을 예측하고, Uplift Modeling 으로 마케팅 증분 효과를 측정하며, CLV 기반 예산 최적화와 A/B 테스트 분석까지 수행하는 End-to-End 리텐션 시스템을 구축한다. 단순히 모델을 만드는 것이 아니라, 누구에게 마케팅을 해야 효과가 있는지 판별하고, 제한된 예산을 어떻게 배분해야 ROI 가 극대화되는지 의사결정하는 전체 프로세스를 경험한다.

#2. 최종 결과물

다음 4 가지 기능이 정상 동작하는 GitHub 레포지토리(Repository) URL 을 제출한다.

레포지토리는 docker-compose up 명령으로 한 번에 실행되어야 한다.

1. 이탈 예측 파이프라인
 - 입력 : python src/main.py --mode train 명령 실행
 - 출력 : models/ 폴더에 학습된 모델 파일이 저장되고, results/ 폴더에 AUC-ROC, SHAP Summary Plot 이 생성된다
2. Uplift 기반 고객 세그멘테이션
 - 입력 : python src/main.py --mode uplift 명령 실행
 - 출력 : results/ 폴더에 고객별 Uplift Score 와 4 분면 세그먼트(Persuadables, Sure Things, Lost Causes, Sleeping Dogs) 분류 결과가 CSV 파일로 저장된다
3. 예산 최적화 및 전략 제안
 - 입력 : python src/main.py --mode optimize --budget 50000000 명령 실행
 - 출력 : results/ 폴더에 세그먼트별 예산 배분 결과와 예상 ROI 가 저장된다
4. 통합 대시보드
 - 입력 : 브라우저에서 <http://localhost:8501> 접속
 - 출력 : 이탈 위험 현황, Uplift 세그먼트 분포, 예산 최적화 시뮬레이션 화면이 표시된다
5. 필수 산출물 체크리스트

산출물	파일/폴더 경로	확인 방법
피처 딕셔너리	docs/feature_dictionary.md	30개 이상 피처 정의
모델 리포트	docs/model_report.md	ML/DL 비교 포함
리텐션 전략 제안서	docs/retention_strategy.md	6세그먼트 전략 포함
CLV 예측 결과	results/clv_predictions.csv	고객별 CLV + Top-20%
6세그먼트 분류 결과	results/segments_6plus.csv	priority score 포함
모니터링 리포트	results/monitoring_report.json	PSI/KS + 임계치 초과 기록
A/B 테스트 리포트	docs/ab_test_report.md	Power 분석 + p-value
Uplift 분석 문서	docs/uplift_analysis.md	Qini Curve + 4분면 해석
SHAP Summary Plot	results/shap_summary.png	상위 10개 피처 중요도

#3. 과제 목표

이 과제를 마친 후, 학습자는 아래를 스스로 설명할 수 있어야 한다.

- 코호트 분석을 통해 가입 시점별 고객 이탈 패턴을 분석하고 해석할 수 있다.
- RFM 피처와 행동 변화율 피처의 설계 원리 및 비즈니스 의미를 설명할 수 있다.
- Uplift Modeling 과 단순 이탈 예측의 차이를 이해하고, Persuadables 와 Sleeping Dogs 식별의 비즈니스 가치를 설명할 수 있다.
- CLV 와 Uplift Score 를 결합하여 마케팅 예산 배분을 최적화하는 방법을 이해한다.
- A/B 테스트의 통계적 유의성 판단 방법과 Power Analysis 의 역할을 설명할 수 있다.
- Treatment/Control 그룹 배정 방식과 교란 통제 전략의 타당성을 설명할 수 있다.

#4. 목표 수행 시간 : 240 시간 (주 40 시간 학습 기준 6W)

#5. 기능 요구 사항

다음 요구사항을 모두 만족해야 한다.

1. 고객 행동 시뮬레이터

- config/simulator_config.yaml 파일에 최소 6 가지 고객 페르소나(VIP 충성고객, 일반충성고객, 가격민감형, 탐색형, 이탈진행형, 신규가입자)를 정의하고 각각의 행동 패턴을 모델링해야 한다
- 고객별로 방문(page_view), 검색(search), 장바구니(add_to_cart/remove_from_cart), 구매(purchase), 쿠폰사용(coupon_use), 리뷰(review), CS 문의(cs_contact) 등 최소 8 가지 이벤트 유형을 생성해야 한다
- 시간 경과에 따른 행동 변화(방문 빈도 감소, 구매 주기 증가, 세션 시간 단축 등)를 시뮬레이션해야 한다
- 마케팅 개입(쿠폰 발송, 푸시 알림 등)에 대한 고객 반응(전환, 무반응, 역효과)을 페르소나별로 차등 모델링해야 한다
- 최소 20,000 명의 고객에 대해 12 개월 이상의 행동 로그를 생성해야 한다 (small 모드: 5,000 명/6 개월)
- 이탈 정의(예: 30 일 미구매 또는 60 일 미접속)를 설정(config) 파일에서 변경할 수 있어야 한다
- 마케팅 Treatment 그룹과 Control 그룹을 자동으로 각각 10,000 명 이상 분리하여 레이블링해야 한다
- 생성된 데이터의 이탈률이 15% 이상 25% 이하여야 한다.

2. 코호트 및 고객 여정 분석

- 가입월 기준 코호트별 M1, M3, M6, M12 리텐션 곡선(Retention Curve)을 산출해야 한다
- 코호트별 이탈률 차이를 분석하고 시각화해야 한다
- 코호트별 리텐션 곡선 시각화 파일이 results/ 폴더에 저장되어야 한다.
- 이탈 고객의 마지막 30 일 행동 시퀀스에서 공통 패턴상위 5 개가 추출되어야 한다.
- 이탈 직전 주요 이벤트(장바구니 포기, CS 문의 등)의 빈도를 분석해야 한다
- 고객 여정 퍼널(가입 → 첫구매 → 재구매 → 충성 → 이탈)별 전환율과 이탈 시점을 분석해야 한다

3. 피처 엔지니어링 (Feature Engineering)

- RFM 피처(Recency, Frequency, Monetary)를 산출해야 한다
- docs/feature_dictionary.md 파일에 30 개 이상의 피처 정의가 작성되어야 한다.
- 행동 변화율 피처를 최소 5 개 이상 설계해야 한다
 - 예시: 최근 2 주 방문수 / 이전 2 주 방문수, 구매 주기 변화율, 세션 시간 변화율, 장바구니 전환율 변화, 쿠폰 반응률 변화다
- 구매 주기 이상 피처(현재 미구매 일수 / 평균 구매 주기)를 산출해야 한다
- 세션 품질 피처(평균 세션 시간, 페이지뷰/세션, 검색 후 구매 전환율) 최소 3 개 이상 산출해야 한다
- 시퀀스 피처를 최소 2 개 이상 설계해야 한다
 - 예시: 최근 N 개 이벤트 타입 시퀀스 임베딩, 행동 패턴 클러스터 ID

- 시간대별 행동 피처(주말/평일 구매 비율, 특정 시간대 활동 비율)를 산출해야 한다
- 고객 여정 단계 피처(현재 여정 단계, 단계별 체류 기간)를 산출해야 한다
- 모든 피처에 대해 결측치 처리와 이상치 처리 로직을 구현해야 한다
- 피처 산출 결과를 피처 스토어(Redis 또는 파일 기반)에 저장해야 한다

4. 이탈 예측 모델 - ML 기반

- 최소 2 가지 이상의 트리 기반 모델(XGBoost, LightGBM, CatBoost 중 선택)을 학습하고 성능을 비교해야 한다
- 클래스 불균형 처리 방법(SMOTE, class_weight, Focal Loss 중 선택)을 적용해야 한다
- 5-Fold Cross Validation 을 수행해야 한다
- 테스트 데이터에 대해 AUC-ROC 0.78 이상을 달성해야 한다 (업계 평균 0.75 대비 +0.03 목표)
- SHAP 을 사용하여 전역 피처 중요도(Global Importance)와 개별 예측 해석(Local Interpretation)을 생성해야 한다
- SHAP Summary Plot 이 results/ 폴더에 저장되어야 한다.
- 상위 10 개 피처 중요도가 출력되어야 한다.
- 이탈 확률 임계값(threshold)에 따른 Precision-Recall Trade-off 를 분석하고 비즈니스 목적에 맞는 임계값을 선정해야 한다
- 하이퍼파라미터 튜닝(Grid Search 또는 Optuna)을 수행해야 한다

5. 이탈 예측 모델 - 딥러닝 기반

- 고객 행동 시퀀스를 입력으로 받는 LSTM 또는 Transformer 기반 모델을 구현해야 한다
- 시퀀스 데이터 전처리(패딩, 임베딩)를 구현해야 한다
- Early Stopping 을 적용해야 한다
- ML 모델과 DL 모델의 성능을 동일한 테스트셋에서 비교해야 한다
- 애플리케이션(ML + DL 결합) 방식의 성능 향상 여부를 실험해야 한다
- DL 모델 파일/학습 로그/ML 대비 비교 리포트를 저장하고, 모델 선택 근거를 문서화해야 한다

6. Uplift Modeling

- 시뮬레이터에서 생성된 Treatment/Control 데이터를 활용해야 한다
- 최소 2 가지 Uplift Modeling 방법(T-Learner, S-Learner, X-Learner, 또는 Causal Forest 중 선택)을 구현하고 비교해야 한다
- 고객별 Uplift Score(CATE: Conditional Average Treatment Effect)를 산출해야 한다
- Uplift Score 를 기준으로 고객을 4 분면으로 분류해야 한다
 - Persuadables: 마케팅 효과 있음 (Uplift > 0, 기본 이탈 확률 높음)
 - Sure Things: 마케팅 없이도 유지 (Uplift ~ 0, 기본 이탈 확률 낮음)
 - Lost Causes: 마케팅해도 이탈 (Uplift ~ 0, 기본 이탈 확률 높음)
 - Sleeping Dogs: 마케팅하면 역효과 (Uplift < 0)

- Qini Curve 또는 Uplift Curve 를 그려 모델 성능을 평가하고 results/ 폴더에 저장되어야 한다.
- Persuadables 세그먼트의 특성을 분석하여 타겟팅 기준을 도출해야 한다

7. CLV 예측

- 확률 모델(BG/NBD + Gamma-Gamma) 또는 머신러닝 기반 중 하나를 선택하여 구현해야 한다
- 향후 12 개월 기준 고객별 예상 CLV 를 산출해야 한다
- CLV 분포를 분석하고 상위 20% 고객을 고가치 고객으로 분류해야 한다
- CLV 예측의 정확도를 검증(실제 vs 예측 비교)해야 한다
- 고객별 CLV 산출 결과를 results/clv_predictions.csv 로 저장하고, Top-N 및 분포 리포트를 포함해야 한다

8. 고객 세그멘테이션 및 우선순위

- 이탈 확률, Uplift Score, CLV 를 기준으로 고객을 최소 6 개 세그먼트로 분류해야 한다
 - 예시: 고가치-Persuadables(최우선), 고가치-Sure Things(유지), 고가치-Lost Causes(심층 분석), 저가치-Persuadables(비용 효율적 개입), 저가치-Lost Causes(No Action), 신규고객(온보딩)
- 각 세그먼트별 고객 수, 비율, 평균 CLV, 평균 이탈 확률을 산출해야 한다
- 리텐션 우선순위 점수(예: Uplift Score x CLV)를 산출해야 한다
- 세그먼트 분류 결과를 시각화해야 한다

9. 리텐션 전략 및 예산 최적화

- 세그먼트별로 차별화된 리텐션 전략(쿠폰 금액, 개인화 메시지, VIP 전담 등)이 docs/retention_strategy.md 에 정의되어야 한다
- 전략별 예상 비용과 예상 효과(Uplift 기반 전환율)를 정의해야 한다
- 총 마케팅 예산 제약 하에서 Expected Revenue 를 최대화하는 예산 배분을 산출해야 한다
 - 목적함수: $\text{Maximize } \sum (\text{Uplift}_i \times \text{CLV}_i \times \text{Action}_i)$
 - 제약조건: $\sum (\text{Cost}_i \times \text{Action}_i) \leq \text{Budget}$
- 예산 최적화는 베이스라인(그리디 또는 선형계획 중 1 개)을 먼저 구현하고, 정교한 제약/다중 목표는 확장 과제로 안내한다
- What-if 분석(예산 50%, 100%, 200% 시나리오)을 수행할 수 있어야 한다
- 최적화 결과에 따른 예상 ROI 를 산출해야 한다

10.A/B 테스트 설계 및 분석

- 시뮬레이터 데이터를 활용하여 가상 A/B 테스트를 설계해야 한다
- 필요 샘플 사이즈를 통계적으로 산출(Power Analysis)해야 한다
- Treatment 그룹과 Control 그룹의 이탈률 차이에 대한 통계적 유의성을 검정(Chi-square 또는 Z-test)해야 한다
- 95% 신뢰구간과 p-value 를 산출해야 한다
- 통계적 유의성 여부($p < 0.05$)가 명시되어야 한다.
- A/B 테스트 결과 해석 리포트를 생성해야 한다

11. 통합 대시보드

- 전체 고객의 이탈 위험 분포를 시각화해야 한다
- 코호트별 리텐션 곡선을 표시해야 한다
- Uplift 4 분면 세그먼트 분포를 시각화해야 한다
- CLV 분포와 상위 고객 목록을 표시해야 한다
- 리텐션 예산 배분 결과와 예상 ROI 를 표시해야 한다
- A/B 테스트 결과 요약을 표시해야 한다
- 리텐션 대상 고객 목록(우선순위순)을 조회할 수 있어야 한다
- 6 세그먼트 분류 결과 및 priority score 시각화를 포함해야 한다
- 데이터는 수동 새로고침으로 업데이트되어야 한다

12. 모델 모니터링

- 피처 분포 변화(Data Drift)를 탐지(PSI 또는 KS-test 기반) 하는 로직을 구현해야 한다
- 모델 성능 지표(AUC, Precision, Recall)의 시간별 변화를 추적해야 한다
- Data Drift 또는 성능 저하 발생 시 알림을 생성해야 한다
- results/monitoring_report.json 에 PSI/KS 계산 결과 및 임계치 초과 기록을 저장해야 한다

13. 문서화 및 코드 품질

- README.md 에 시스템 아키텍처 다이어그램을 포함해야 한다
- docs/feature_dictionary.md 에 피처 설계 근거와 각 피처의 비즈니스 의미를 문서화해야 한다
- docs/model_report.md 에 모델 학습 과정과 성능 평가 결과를 문서화해야 한다
- docs/retention_strategy.md 에 Uplift Modeling 적용 과정과 세그먼트 해석을 문서화해야 한다
- 세그먼트별 리텐션 전략 제안서를 작성해야 한다
- A/B 테스트 결과 해석 리포트를 작성해야 한다
- 주요 함수에 docstring 을 작성해야 한다
- 프로젝트 구조가 모듈별로 분리되어 있어야 한다

#7. 제약 사항

• 개발 환경

- Python 3.10 이상을 사용해야 한다
- PyTorch 2.0 이상을 사용해야 한다
- Docker 및 Docker Compose 를 사용해야 한다
- 전체 시스템은 docker-compose up 명령어 하나로 실행되어야 한다
- GPU 없이 CPU 환경에서도 전체 시스템이 동작해야 한다 (딥러닝 모델 학습은 소규모 데이터로 검증)

• 데이터

- 외부 실제 고객 데이터를 사용하지 않고, 시뮬레이터로 생성한 데이터만 사용해야 한다
- 시뮬레이터의 고객 페르소나, 행동 패턴, 마케팅 반응 모델을 문서에 명시해야 한다
- 생성 데이터의 통계적 특성(이탈률 15-25%, Uplift 분포)이 현실적인 범위여야 한다
- Treatment/Control 그룹은 무작위 배정 또는 성향 점수 매칭으로 구성해야 한다
- 참고 데이터셋(UCI Online Retail, Kaggle E-Commerce 등)은 시뮬레이터 설계 시 참고 용도로만 활용한다.
- **모델링**
 - 이탈 예측에 AutoML 도구(AutoSkllearn, H2O 등)를 메인 모델로 사용하지 않는다
 - Uplift Modeling 은 직접 구현하거나 CausalML, EconML 라이브러리를 사용할 수 있다
 - CLV 예측에 Lifetimes 라이브러리를 사용할 수 있다
 - SHAP 해석은 필수로 포함해야 한다
 - 딥러닝 모델(LSTM, Transformer)은 PyTorch 로 직접 구현해야 한다
 - 모델 학습 코드와 평가 코드가 분리되어 있어야 한다
- **최적화**
 - 예산 최적화는 직접 구현하거나 SciPy, PuLP, OR-Tools 등을 사용할 수 있다
 - 최적화 목적함수와 제약조건을 수식으로 명확히 정의해야 한다
- **대시보드**
 - Streamlit, Dash, Gradio 중 하나를 사용해야 한다
 - 외부 유료 BI 도구는 사용하지 않는다
- **통계 검정**
 - A/B 테스트 유의성 검정에 scipy.stats 를 사용할 수 있다
 - 유의수준은 0.05 를 기준으로 한다
 - 검정력(Power)은 0.8 이상을 목표로 한다.
- **코드 품질**
 - 하드코딩된 파일 경로, 비밀번호 등은 환경 변수 또는 설정 파일(config 파일)로 분리해야 한다
 - 주요 함수에는 docstring 을 작성해야 한다
 - 프로젝트 구조는 모듈별로 분리되어야 한다
 - Git Flow 또는 GitHub Flow 브랜치 전략을 사용해야 한다
- **제출 형식**
 - GitHub 레포지토리 URL 만 제출한다.
 - main 브랜치에 최종 코드가 있어야 한다.
 - 제출 시점에 레포지토리가 Public 상태여야 한다.

#8. 보너스 과제 (선택)

1. 보너스 1 - 실시간 이탈 위험 스코어링

- 해야 할 작업: Kafka 또는 Redis Streams 를 사용하여 실시간 이벤트 스트림을 처리하고, 고객별 이탈 위험 점수를 실시간으로 업데이트하는 파이프라인을 구현한다.
- 배움 포인트: 배치 처리와 실시간 처리의 아키텍처 차이를 체감하고, 스트림 처리 프레임워크를 경험한다.

2. 보너스 2 - 이탈 시점 예측 (Survival Analysis)

- 해야 할 작업: Cox Proportional Hazards 또는 Survival Random Forest 를 사용하여 "언제" 이탈할지 시점을 예측하는 모델을 구현한다.
- 배움 포인트: Survival Analysis 기법의 비즈니스 활용을 경험하고, 이진 분류와 생존 분석의 차이를 이해한다.

3. 보너스 3 - 개인화 추천 연동

- 해야 할 작업: 이탈 위험이 높은 고객에게 개인화 상품 추천을 제공하는 모듈을 구현하고, 추천 상품이 대시보드에 표시되도록 연동한다.
- 배움 포인트: 이탈 예측 모델과 추천 시스템의 연동을 경험하고, 리텐션 전략의 개인화 방안을 이해한다.

4. 보너스 4 - MLflow 기반 실험 관리

- 해야 할 작업: MLflow 로 모델 학습 실험을 추적하고, 모델 레지스트리에 버전 관리를 구축한다. 모델 서빙까지 연동한다.
- 배움 포인트: ML 실험 관리의 중요성과 모델 버전 관리, 배포 자동화를 체감한다.

#9. 동료 평가 질문 예시

1. 기능 동작 검증

- [] docker-compose up 명령으로 전체 시스템이 정상 실행되는가?
- [] 시뮬레이터가 20,000 명 이상의 고객 데이터를 생성하는가?
- [] Treatment/Control 그룹이 각각 10,000 명씩 분리되어 있는가?
- [] 코호트 분석 결과가 M1, M3, M6, M12 리텐션을 표로 출력되는가?
- [] RFM 피처, 행동 변화 피처, 시퀀스 피처가 정상 산출되는가?
- [] ML/DL 기반 이탈 예측 모델이 모두 학습되고 예측 결과가 출력되는가?
- [] CLV 가 산출되고 results/clv_predictions.csv 에 고가치 고객이 식별되는가?
- [] DL 모델 파일/학습 로그/ML 대비 비교 리포트가 저장되어 있는가?
- [] results/monitoring_report.json 에 PSI/KS 결과 및 임계치 초과 기록이 있는가?
- [] A/B 테스트에 Power 분석(목표 power ≥ 0.8) 또는 표본수 산정 근거가 리포트에 포함되는가?
- [] 30 개 이상의 피처가 feature_dictionary.md 에 정의되어 있는가?
- [] ML 모델의 AUC-ROC 가 0.78 이상인가?
- [] SHAP Summary Plot 이 results/ 폴더에 생성되는가?
- [] Uplift Score 와 4 분면 세그먼트 분류 결과가 CSV 로 출력되는가?

- [] 예산 입력 시 최적 배분 결과와 ROI 가 산출되는가?
- [] A/B 테스트 p-value 와 95% 신뢰구간이 산출되는가?
- [] 대시보드(<http://localhost:8501>)에서%EC%97%90%EC%84%9C) 이탈 현황과 세그먼트 분포를 확인할 수 있는가?

2. 코드 구조 및 설계

- [] 시뮬레이터, 피처, 모델, 최적화, 대시보드가 기능별로 모듈 분리되어 있는가?
- [] 설정값(하이퍼파라미터, 경로, 임계값 등)이 config 파일로 관리되는가?
- [] 새로운 피처 추가 시 기존 코드 수정이 최소화되는 구조인가?
- [] 모델 학습 코드와 추론 코드가 분리되어 있는가?
- [] 주요 함수에 docstring 이 작성되어 있는가?
- [] docs/ 폴더에 feature_dictionary.md, model_report.md, retention_strategy.md 가 작성되어 있는가?

3. 핵심 기술 원리 적용

- [] 코호트 분석이 가입월 기준으로 올바르게 수행되었는가?
- [] RFM 피처가 정의(Recency, Frequency, Monetary)에 맞게 산출되었는가?
- [] 행동 변화율 피처가 이탈 징후를 포착하는 데 유의미한가?
- [] Uplift Model 이 Treatment/Control 데이터를 활용하여 CATE 를 학습했는가?
- [] 4 분면 세그먼트 분류 기준이 Uplift Score 와 이탈 확률을 기반으로 하는가?
- [] 예산 최적화의 목적함수와 제약조건이 retention_strategy.md 에 수식으로 명시되었는가?
- [] A/B 테스트가 적절한 통계 검정 방법(Chi-square, Z-test 등)으로 수행되었는가?
- [] Treatment/Control 배정 방식과 교란 통제 전략(무작위/PSM 등) 선택 이유 및 검증(밸런스 체크) 방법이 적절한가?