

Chapter 1

음성인식 연구 동향 및 문제 정의

김지환

서강대학교 컴퓨터공학과

Table of contents

1.1 음성인식 문제 정의

1.2 음성인식 연구 동향

1.3 GPT-1 이후 동향

1.1 음성인식 이란?

- ❖ 마이크를 통해 입력 받은 음성(speech)이 주어졌을 때, 확률이 가장 높은 문장(단어의 열)을 출력



“안녕하세요”

$$\arg_w \max P(W|X)$$

- $W = \{w_1, w_2, \dots, w_U\}$: U 개의 단어시퀀스
- $X = \{x_1, x_2, \dots, x_T\}$: 음성시퀀스

1.1 E2E 관점의 음성인식 문제정의

◆ 음성인식을 입력end (음성)에서 출력end (문장)으로의 변환의 문제로 본다면

❖ 음성인식문제는

- $x_1 \dots x_T$ (Continuous vector space에서의 13차 벡터 T 개의 시퀀스)에서 $w_1 \dots w_U$ (V 개의 서로 다른 값을 가지는 discrete symbol U 개의 시퀀스)로의 번역문제로 재정의할 수 있다

◆ 완벽한 E2E 시스템 구현은 불가능

- 이상적인 E2E 시스템: 전체 시스템을 블랙박스로 보고 데이터만 주면 알아서 시스템이 학습하는 방식
- 무한개의 입력 시퀀스에서 무한개의 출력 시퀀스로 매핑하는 시스템은 구현이 불가능하다

1.1 E2E 음성인식 구현 시 입출력 복잡도

◆ 음성인식 시스템의 가능한 입력 개수 분석

- 가정: 입력 길이 1초, 44.1K, 샘플 당 2byte 사용
- 저장에 $1 \times 44100 \times 2 = 88,200$ byte 필요
- 가능한 입력의 개수: $2^{88200 \times 8}$
- 입력 길이의 제한이 없으므로 가능한 입력의 개수는 무한대이다

◆ 음성인식 시스템의 가능한 출력 개수 분석

- 어휘를 구성하는 단어의 수(V): 무한대(지명, 인명 등 제한이 없으며 신조어가 계속해서 생성된다)
- 연속음성인식에서는 입력 파형만을 가지고 몇 개의 단어로 구성된 문장인지 알 수 없다

1.1 DNN-WFST에서의 문제 정의

$$\mathit{arg}_W \max P(W|O)$$

■ 기호 설명

- $W: w_1 \dots w_N$
 - N개의 단어들로 이루어진 문장
- $O: o_1 \dots o_T$
 - T개의 윈도우에서 각 윈도우로부터 나온 13차 vector의 sequence.

- 가능한 O의 개수가 무한대이기 때문에 $P(W|O)$ 를 직접 구할 수 없음

1.1 DNN-WFST에서의 문제 정의

- Bayesian rule을 적용하여 변환


$$\mathit{arg}_W \max P(W|O) = \mathit{arg}_W \max \frac{P(O|W)P(W)}{P(O)}$$

- P(O): 13 * T 벡터 공간에서의 한 점의 확률
- 이 확률을 모두 동일하다고 가정하면 $\mathit{arg}_W \max$ 를 찾는 문제이기 때문에 P(O)를 생략 가능


$$\underbrace{\mathit{arg}_W \max}_{\text{디코딩}} \underbrace{P(O|W)}_{\text{음향 모델}} \underbrace{P(W)}_{\text{언어 모델}}$$

- 음성인식 시스템 구성에서의 핵심
 - 음향 모델 $P(O|W)$
 - 언어 모델 $P(W)$
 - 디코딩 네트워크($\mathit{arg}_W \max$)
 - 어휘(인식 가능한 단어 set)의 구현이다.

1.2 주요 음성인식 모델



DNN-WFST 기반 음성인식 파이프라인



End-to-end 기반 음성인식 파이프라인

■ DNN-WFST

- Kaldi(음성인식 주요 tool)의 기반
- E2E에 대응되는 기술로서 술되나, Frame 단위까지(출력 end가 HMM에서의 state)의 E2E임

■ E2E (출력 end는 주로 grapheme)

- CTC
- RNN-T
- Attention
- Transformer

1.2 E2E방법의 장점 및 주요 검토 항목

◆ 장점

- SOTA(State-of-the-art)를 보임 (transformer)
- 음성파일과 이에 대응되는 transcription만으로 학습
- 전혀 모르는 언어에 대해서도 음성인식기 제작이 가능

◆ 단점

- 외부지식을 실시간 반영할 수 있는 방법이 없음 (예: 실시간 검색어(고유명사 많음))
- 대용량 텍스트 코퍼스를 음성인식기에 직접 반영할 수 있는 방법이 없음

1.2 주요 E2E 방법

◆ End-to-end models

- Connectionist temporal classification (CTC) [Graves, 2006]
 - 알파벳과 음성 정보만으로 단일 모델을 구성할 수 있는, 최초로 제안된 end-to-end 음성인식 모델
- RNN-transducer (RNN-T) [Graves, 2012]
 - CTC에 언어 정보를 학습할 수 있는 RNN 기반의 모델을 추가하여 성능을 개선시킨 모델
- Attention 기반 seq2seq [Chan, 2016]
 - 음성인식을 sequence의 번역으로 해석해서 attention mechanism을 적용한 모델
- Transformer [Vaswani, 2017]
 - Multi-head self-attention을 사용하여 RNN 없이 sequence 모델링을 구현한 모델

1.2 주요 E2E 방법

◆ Librispeech corpus 대상 end-to-end 음성인식 모델 성능 비교

System	WER(%)	WER with 2 nd -pass LM(%)	Streaming 가능 여부	성능 재현 여부
DNN-WFST [Han, 2019]	2.93	2.20	O	O
CTC [Li, 2019]	3.86	2.95	O	O
RNN-T [Zeyer, 2021]	3.30	2.36	O	O
Attention-based seq2seq [Park, 2019]	2.80	2.50	X	O
Transformer (seq2seq) [Karita, 2019]	2.20	2.10	O	X
Transformer (RNN-T) [Anmol, 2020]	2.10	1.9	O	X

1.2 주요 E2E 방법

◆ Librispeech corpus 대상 end-to-end 음성인식 모델 성능 비교

System	WER(%)	WER with 2 nd -pass LM(%)	Streaming 가능 여부	성능 재현 여부
wav2vec 2.0 large [Baevski, 2020]	2.20	1.80	X	○
Whisper large-v2 [Radford, 2023]	2.50	N/A	X	○
SALMONN [Tang, 2024]	2.10	N/A	X	○
Qwen-Audio [Chu, 2023]	2.00	N/A	X	○
Qwen2-Audio [Chu, 2024]	1.60	N/A	X	○
Qwen2.5-Omni [Xu, 2025]	1.80	N/A	○	○

1.2 주요 E2E 방법

◆ 대용량 corpus 대상 end-to-end 음성인식 모델 성능

System	Training data	Test data	WER(%)	WER with 2 nd -pass LM(%)	비고
CTC [Pratap, 2020]	Multilingual Librispeech (MLS) English (44, 659 hours)	Librispeech test-clean	2.94	1.83	
CTC [Narayanan, 2018]	Youtube (117,000 hours)	Youtube	N/A	15.9	
CNN+Transformer+RNN-T [Yu, 2021]	Multidomain Data (413,000 hours)	Google voice search	5.2	N/A	Google Voice Search, Farfield Speech, YouTube and Meetings
RNN-T [Yu, 2021]			5.1	N/A	
RNN-T+seq2seq [Sainath, 2020]			6.4	N/A	

1.2 주요 E2E 방법

◆ 대용량 corpus 대상 end-to-end 음성인식 모델 성능

System	Training data	Test data	WER(%)	WER with 2 nd -pass LM(%)	비고
Whisper large-v2 [Radford, 2023]	Web-scale weakly labeled speech data (680,000 hours)	Common Voice 5.1 English	9.00	N/A	
SALMONN [Tang, 2024]	Librispeech 960h + Gigaspeech 1,000h	GigaSpeech Test	9.10	N/A	
Qwen-Audio [Chu, 2023]	Multilingual ASR (30,000h) + multi-task audio data	AISHELL-2 Mic / iOS / Android	3.3 / 3.1 / 3.3	N/A	

1.3 GPT-1 이후 동향

Model & year	Key Change	Ref papers
GPT-1 · 2018	비지도 사전학습 → task별 supervised fine-tuning	[1] Radford et al. (2018), Improving Language Understanding by Generative Pre-Training
GPT-2 · 2019	task-specific 학습 없이 zero-shot 수행 및 장문 생성	[2] Radford et al. (2019), Language Models are Unsupervised Multitask Learners
GPT-3 · 2020	prompt의 지시·예시로 zero-shot/few-shot task 수행	[3] Brown et al. (2020), Language Models are Few-Shot Learners
InstructGPT/ChatGPT & Alignment · 2021–23	Instruction Tuning, RLHF 등으로 지시 준수 및 선호 정렬	[4] Wei et al. (2021), Finetuned Language Models Are Zero-Shot Learners [5] Ouyang et al. (2022), Training Language Models to Follow Instructions with Human Feedback [6] Rafailov et al. (2023), Direct Preference Optimization: Your Language Model is Secretly a Reward Model
GPT-4o · 2024	text·vision·audio 등의 다중 모달리티를 단일 모델에서 실시간 통합 처리	[7] OpenAI (2024), Hello GPT-4o [8] OpenAI (2024), GPT-4o System Card [9] Xu et al. (2025), Qwen2.5-Omni Technical Report
CoT / OpenAI-o1 / DeepSeek-R1 · 2022–25	중간 풀이 유도 → RL로 학습된 장기 추론	[10] Wei et al. (2022), Chain-of-Thought Prompting Elicits Reasoning in Large Language Models [11] OpenAI (2024), OpenAI o1 System Card [12] DeepSeek-AI et al. (2025), DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning
Agents · 2022~	추론과 tool action을 교차하며 외부 환경과 상호작용	[13] Yao et al. (2023), ReAct: Synergizing Reasoning and Acting in Language Models [14] Schick et al. (2023), Toolformer: Language Models Can Teach Themselves to Use Tools
Scaling Laws / MoE / PEFT (LoRA) · 2020~	최적 확장·희소 활성화·저비용 adaptation	[15] Kaplan et al. (2020), Scaling Laws for Neural Language Models [16] Hoffmann et al. (2022), Training Compute-Optimal Large Language Models [17] Fedus et al. (2022), Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity [18] Hu et al. (2022), LoRA: Low-Rank Adaptation of Large Language Models